FluxIA — Especificação Completa de Arquitetura & IA

Documento de Engenharia, Pipeline RAG, Governança e Guia de Diagramação

Público-Alvo: Sócios, Executivos e Equipe Técnica **Versão:** 2.0.0 Definitiva **Classificação:** Documento Estratégico

Sumário Executivo

O **FluxIA** é uma plataforma SaaS B2B multitenant desenvolvida para transformar o canal do Telegram em uma máquina comercial ativa, integrada em tempo real a um CRM completo e a um motor de IA com RAG de ponta. Diferente de bots convencionais que dependem de prompts genéricos, o FluxIA opera sob rigorosas garantias corporativas: **isolamento estrito de dados entre empresas clientes (Zero Data Leakage)**, **fidelidade absoluta aos preços oficiais e combate ativo a alucinações**, **controle financeiro de custos de IA em tempo real (FinOps)**, **deduplicação matemática por SHA-256** e **transbordo instantâneo para atendimento humano com salvaguarda de 30 minutos de ociosidade**.

1. Topologia Geral e Decisões de Engenharia

- **Front-end No-Build (HTML5 + CSS3 + Vanilla JS):** Elimina etapas de compilação pesadas (Node.js/npm/Webpack), garantindo carregamento instantâneo (< 100ms), imunidade a falhas de pacotes externos e ergonomia estilo WhatsApp Web em 3 colunas.
- **Back-end FastAPI Assíncrono com APScheduler:** Conexão não-bloqueante para dezenas de webhooks simultâneos do Telegram. O APScheduler roda em segundo plano na mesma instância executando follow-up periódico a cada 1 hora e timeout de operadores ociosos a cada 5 minutos.
- **PostgreSQL Multitenant com DDL Idempotente:** Todas as tabelas possuem empresa_id. A função criar_banco() roda no startup criando tabelas e índices de forma automática e segura (IF NOT EXISTS).

2. Pipeline de Ingestão e o Papel do Hash SHA-256

O pipeline de ingestão converte arquivos e documentos corporativos em representações vetoriais semânticas sob rígido controle de integridade:

- **A Impressão Digital Matemática (SHA-256):** No momento do upload, antes de salvar no disco ou chamar a IA, o sistema lê os bytes brutos e gera o hash SHA-256 de 64 caracteres hexadecimais (hashlib.sha256(bytes).hexdigest()).
- **Filtro de Duplicatas e Prevenção de Custos (FinOps):** O banco verifica se já existe registro com o mesmo nome ou mesmo hash para o empresa_id. Se o usuário renomear o arquivo (ex: de tabela.pdf para tabela_nova.pdf), o hash bloqueia com HTTP 409, impedindo gasto desnecessário de tokens de embedding da API do Gemini.
- **Anti-Diluição do Contexto RAG:** Evita que o mesmo parágrafo seja indexado em triplicata, o que saturaria o Top-3 da busca semântica com conteúdo repetido e impediria a leitura de outros manuais.
- **Extração Multimodal com OCR via Gemini Vision:** Arquivos .png, .jpg e .jpeg são processados pelo Gemini multimodal, que transcreve textos visuais (OCR) e descreve o contexto em português para ser vetorizado.
- **Algoritmo de Chunking com Janela Deslizante:** Divide textos em blocos de ~1000 caracteres com sobreposição de 200 caracteres, cortando sempre no último espaço para nunca quebrar palavras ao meio.
- **Embeddings em 768 Dimensões:** Modelo models/gemini-embedding-001 com tratamento de cota 429 via retries progressivos (15s, 30s, 45s...).
- **Trava de Segurança RBAC:** Apenas usuários com perfil admin ou master podem subir arquivos ou cadastrar notas dinâmicas via chat (POST /chat/). Colaboradores recebem recusa cordial.

3. Motor RAG e Busca Semântica Avançada

- **Barreira de Segurança (Público vs. Interno):** No bot do Telegram, o SQL filtra estritamente COALESCE(d.nivel_acesso, 'publico') = 'publico'. Documentos confidenciais (margens, contratos, salários) só são acessíveis por colaboradores no portal web.
- **Similaridade de Cosseno em Memória:** Vetores normalizados comparados matematicamente. Limiar de 0.70 no portal e 0.25 no Telegram (tolerância para linguagem coloquial).
- **Expansão de Contexto por Vizinhança (N-1, N, N+1):** Ao localizar o melhor chunk semântico (ex: chunk 5), o sistema busca automaticamente os vizinhos imediatos (chunks 4 e 6) do mesmo documento e os organiza em ordem cronológica ($4 \rightarrow 5 \rightarrow 6$), garantindo parágrafos completos sem cortes para o LLM.

4. Agente Gerente e Classificador Semântico Central

- **Máquina de Estados Bot vs. Humano:** Se status == 'humano', a IA cala a boca e grava a mensagem para o operador. Se o atendente sumir por 30 minutos, o sistema reverte automaticamente para o bot.
- **Extração de Entidades e Turno Único:** Isola nome real e WhatsApp com DDD (mínimo 8 dígitos). Se o cliente mandar dados e pergunta juntos, o sistema salva o lead e responde a dúvida no mesmo turno.
- **Classificador em 10 Intenções:** Roda via Gemini 3.5 Flash Lite em JSON com fallback heurístico para mais de 40 regexes. Cobre: BLOQUEIO_PRIVACIDADE (LGPD), COLETA_CONTATO, CADASTRO_CONCLUIDO, SAUDACAO, DESPEDIDA, ENVIO_PDF_PROPOSTA, CONSULTA_STATUS_TICKET, TRANSBORDO_HUMANO, PROPOSTA_COMERCIAL, CONSULTA_COMERCIAL e FORA_DO_ESCOPO.
- **Envio de Proposta em PDF via Telegram:** Gera documento comercial formal estilizado em tempo real via ReportLab e despacha no Telegram com sendDocument.
- **Dossiê Comercial Sigiloso:** Apresenta propostas e contratos do cliente em 1ª pessoa sem nunca expor IDs internos de banco (ex: #18) ou termos técnicos de CRM.
- **Abertura de Ticket com Síntese Executiva em 10s:** Resume as últimas 8 interações em 5 tópicos (Cliente, Interesse, Demanda, Histórico e Ação Recomendada) para o operador humano ler instantaneamente.

5. Motor Multi-Vendor, FinOps e Auditoria Contínua

- **MultiVendorAIEngine (LangChain Core):** Provedor padrão Google (Gemini 3.5 Flash Lite) com failover automático para OpenAI (GPT-4o-mini), e suporte a chaves próprias da empresa (BYOK).
- **FinOps e Telemetria em USD:** O AIObservabilityCallbackHandler grava em ia_telemetria_execucao: tokens_prompt, tokens_completion, latência em ms e calcula o custo estimado em USD com precisão de 7 casas decimais.
- **Auditor Anti-Alucinação (LLM-as-a-Judge):** Executado de forma assíncrona desacoplada via BackgroundTasks. Avalia sob o método **RAG Triad**: *Fidelidade Comercial* (alerta alucinação se inventar preços), *Relevância da Resposta* e *Relevância do Contexto*, persistindo em ia_evaluations.
- **Dashboard Comercial com Inteligência por Produto:** Módulo analítico com cards para ■ Produto Mais Vendido, ■ Maior Faturamento e ■ Maior Pipeline Ativo, acompanhado de tabela comparativa com barra visual de participação percentual.

6. Dicionário de Estruturas Centrais do Banco de Dados

Tabela	Função Estrutégica no Ecossistema
empresas	Raiz multitenant do SaaS (CNPJ, razão social e identificador único).
usuarios	Contas da equipe com papéis RBAC (Master, Admin, Colaborador) e senhas PBKDF2.
configuracoes_empresa	Chaves BYOK (Gemini/OpenAI mascaradas), token bot Telegram e políticas de atendimento.
produtos & pipelines	Catálogo de produtos com preços e etapas configuráveis do funil de vendas.
clientes & negocios	Base de leads qualificados, estágio no funil, valor estimado e histórico comercial.
propostas & contratos	Propostas emitidas (PDF via ReportLab) e contratos formalizados com assinatura.
documentos & chunks	Base de conhecimento com segregação pública/interna, hash SHA-256 e embeddings.
conversas_telegram	Estado operacional do chat (bot vs humano), timeout e atendente responsável.
tickets & mensagens	Fila de atendimento prioritário com síntese executiva por IA em tópicos.
ia_telemetria_execucao	Histórico de FinOps: tokens de prompt/completion, latência em ms e custo em USD.
ia_evaluations	Auditoria contínua da RAG Triad, índice de fidelidade e detecção de alucinações.

7. Guia Oficial de Componentes para o seu Diagrama

Recomendações para a modelagem visual do Diagrama Arquitetural:

• **Gateway & Borda:** Desenhar o Webhook do Telegram (/telegram/webhook/{id}) e o Portal Web (/chat/ e Dashboard) convergindo para a camada de segurança FastAPI com filtro de empresa_id.
• **Orquestrador (O Decisor):** Representar o AgentOrchestrator como nó central conectado ao Extrator de Entidades, ao Classificador de 10 Intenções e à Máquina de Estados (Modo Bot vs Modo Humano).
• **Gateway de Ingestão:** Incluir o nó Deduplication & Integrity Filter (SHA-256) posicionado antes do módulo de Chunking e Embeddings.
• **RAG Engine:** Conectar a busca de cosseno ao mecanismo de Expansão de Vizinhança (N±1) com segregação de acesso (público para Telegram, público+interno para Portal).
• **Multi-Vendor Router:** Representar o MultiVendorAIEngine com roteamento primário Gemini e failover para OpenAI.
• **Observabilidade & Auditoria:** Mostrar a telemetria gravando de forma síncrona na ia_telemetria_execucao e o LLM-as-a-Judge operando assincronamente via BackgroundTasks gravando na ia_evaluations.