FluxIA — Arquitetura de Software e Estratégia de IA

Documento Executivo de Engenharia, Modelo Multitenant e Governança de LLMs

Público-Alvo: Sócios, Executivos e Equipe Técnica	**Versão:** 1.0.0 Oficial	**Classificação:** Documento Estratégico

Sumário Executivo

O **FluxIA** é uma plataforma SaaS B2B multitenant projetada para transformar o canal do Telegram em uma máquina comercial automatizada, integrada em tempo real a um CRM completo e a um motor inteligente de IA. Diferente de soluções convencionais que apenas conectam um prompt genérico ao ChatGPT, o FluxIA opera sob rigorosas garantias empresariais: **isolamento estrito de dados entre empresas clientes**, **fidelidade absoluta aos preços oficiais e combate ativo a alucinações**, **controle financeiro de custos de IA em tempo real** e **transbordo instantâneo para atendimento humano com salvaguardas de inatividade**.

> ***Pilar Estratégico:*** *Desenhado para que qualquer empresa utilize IA em produção comercial com previsibilidade financeira (medição de custos por interação em USD), segurança jurídica (a IA não inventa dados nem expõe documentos internos) e controle operacional contínuo pelos operadores humanos.*

1. Estratégia de Arquitetura: O "Condomínio Comercial"

Para facilitar o entendimento técnico e de negócios, a engenharia do FluxIA foi concebida sob a metáfora de um **Condomínio Comercial de Alto Padrão**:

- **Infraestrutura Compartilhada (SaaS Multitenant):** Todo o edifício (elevadores, portaria, cabeamento) é compartilhado para reduzir custos operacionais. No entanto, **cada empresa possui sua própria sala com chave blindada**. A Empresa A jamais acessa os contatos, negociações ou contratos da Empresa B.
- **Fachada e Recepção (Front-end):** A interface visual operada pelos atendentes e gestores. Desenhada para ser extremamente rápida, intuitiva e sem bloqueios de carregamento.
- **Administração Central (Back-end):** O motor central de regras que valida permissões, calcula propostas, aciona o Telegram e orquestra o funil de vendas.
- **Arquivo Blindado (Banco de Dados PostgreSQL):** Repositório estruturado onde todas as tabelas de negócio possuem segregação lógica por empresa_id.
- **Equipe de IA Especializada:** Divisão modular de inteligência artificial com papéis claros: recepcionista, especialista em manuais, taxímetro financeiro e auditor de conformidade.

2. Decisões Tecnológicas: Frameworks e Escolhas Técnicas

A stack do projeto foi selecionada com base em métricas práticas: **alta concorrência assíncrona, velocidade de entrega ao usuário final, baixo consumo de memória em servidores e simplicidade de manutenção contínua**.

Camada	Tecnologias Utilizadas	Por que foi feita essa escolha?

Front-end	HTML5 Semântico CSS3 (Design Tokens) JavaScript ES6 Puro *(Sem React/Vue)*	**Zero tempo de compilação (No-Build):** Dispensa Node.js/npm em produção. Carregamento instantâneo, ergonomia estilo WhatsApp Web em 3 colunas e Dark/Light mode nativo em CSS sem reflow.
Back-end	Python 3.12 FastAPI / Uvicorn Pydantic v2 APScheduler	**Alta concorrência assíncrona (Async):** Suporta centenas de webhooks simultâneos do Telegram. O APScheduler executa rotinas periódicas (follow-up e timeouts) sem a complexidade de brokers pesados como Redis.
Banco de Dados	PostgreSQL psycopg2-binary RealDictCursor	**Isolamento multitenant estrito:** Toda query filtra por empresa_id. DDLs e migrações idempotentes no startup criam tabelas e colunas automaticamente sem exigir intervenção manual.
Camada de IA	LangChain Core Google GenAI SDK OpenAI SDK text-embedding-004	**Adaptador Multi-Vendor com BYOK:** Permite à empresa usar sua própria chave (Bring Your Own Key) Gemini ou OpenAI, com medição de tokens e auditoria assíncrona de alucinação.

3. Arquitetura da Inteligência Artificial em 4 Camadas

A inteligência artificial do FluxIA opera como um sistema modular em quatro estágios complementares:

Camada 1: O Agente Gerente e Orquestrador (agent_orchestrator.py)

- **Qualificação Obrigatória de Leads:** Identifica nomes genéricos e números inválidos. Se ativada a regra na empresa, a IA conduz o lead a informar nome real e WhatsApp com DDD antes de responder genericamente.
- **Resolução em Turno Único:** Quando o cliente envia dados cadastrais e uma pergunta simultaneamente, a IA grava o contato no CRM e responde a dúvida técnica no mesmo turno de mensagem.
- **Funil Comercial Unidirecional:** O fluxo avança estritamente (novo → qualificado → proposta → negociacao → fechado). A IA nunca regride o estágio automaticamente. Ao atingir fechado, um contrato comercial é gerado automaticamente.

Camada 2: O Motor RAG Semântico e Barreira de Acesso (semantic_search_service.py)

- **Conceito RAG (Retrieval-Augmented Generation):** A IA responde exclusivamente embasada em trechos reais de manuais e arquivos indexados pela própria empresa.
- **Barreira de Segurança (Público vs. Interno):** Documentos com acesso publico alimentam as respostas do bot no Telegram; documentos com acesso interno (propostas, margens e contratos) são blindados no SQL e consultáveis unicamente por colaboradores autenticados no portal web.
- **Embeddings e Limiar de Similaridade:** Geração de vetores matemáticos de 768 dimensões com o Google text-embedding-004. Chunks com similaridade de cosseno inferior a 70% são descartados para evitar alucinações por ruído.

Camada 3: Observabilidade e Governança de Custos (ai_observability_service.py)

- **Telemetria com Callback Handler:** Intercepta em tempo real cada chamada da LLM via LangChain, mensurando tokens de entrada, saída, latência em milissegundos e fornecedor.
- **Cálculo de Custo Estimado (USD):** Aplica a tabela tarifária oficial dos provedores, gravando o custo financeiro exato de cada resposta na tabela ia_telemetria_execucao.

Camada 4: Auditoria Contínua Anti-Alucinação (ai_evaluation_service.py)

- **Padrão LLM-as-a-Judge:** Uma IA independente audita as respostas comerciais do bot com base no método **RAG Triad**:
  1. *Fidelidade Comercial (0 a 100%):* Detecta se a IA inventou preços, descontos ou serviços inexistentes.
  2. *Relevância da Resposta (0 a 100%):* Mede se o cliente teve sua dúvida atendida com clareza e objetividade.
  3. *Relevância do Contexto (0 a 100%):* Confirma se os trechos recuperados da base eram adequados.
- **Execução Assíncrona Não-Bloqueante:** Roda em BackgroundTasks do FastAPI, auditando a qualidade sem atrasar a resposta ao usuário final.

4. Atendimento Híbrido: Bot vs. Transbordo Humano

Para garantir viabilidade comercial, o sistema implementa uma regra de ouro: **a IA acelera o atendimento, mas o operador humano tem total soberania**.

- **Modo Bot:** A IA qualifica o lead, responde dúvidas públicas e avança oportunidades no funil.
- **Transbordo para Humano:** Quando o cliente solicita um humano ou atinge o estágio de proposta, a conversa passa para status = 'humano', gerando um ticket na fila de atendimento.
- **Silenciamento Imediato da IA:** No modo humano, o robô não envia nenhuma mensagem automática. O operador assume e digita pelo portal web estilo WhatsApp Web.
- **Trava de Inatividade de 30 Minutos:** Se o atendente assumir mas ficar inativo por mais de 30 minutos sem responder o cliente, o job em segundo plano devolve o chat ao bot automaticamente, evitando o abandono do lead.

5. Estrutura Central de Dados (PostgreSQL)

Tabela	Função Estrutégica no Ecossistema
empresas	Raiz multitenant do SaaS (CNPJ, razão social e identificador único).
usuarios	Contas da equipe com papéis RBAC (Master, Admin, Colaborador/Atendente) e senhas PBKDF2.
configuracoes_empresa	Chaves BYOK (Gemini/OpenAI mascaradas), bot token Telegram e regras de atendimento.
produtos & pipelines	Catálogo de soluções comerciais e etapas configuráveis do funil de vendas.
clientes & negocios	Base de leads cadastrados, estágio no funil, valor estimado e histórico de follow-up.
propostas & contratos	Emissão de propostas comerciais (PDF com ReportLab) e formalização de contratos ganhos.
documentos & chunks	Base de conhecimento indexada com divisão de acesso (público vs interno) e embeddings.
conversas_telegram	Estado operacional do chat (bot vs humano) e atendente responsável.
tickets & mensagens	Fila de atendimento humano sincronizada bidirecionalmente com o Telegram.
ia_telemetria_execucao	Histórico detalhado de tokens, latência e custo estimado em USD por interação.
ia_evaluations	Auditoria contínua da RAG Triad, índice de fidelidade e detecção de alucinações.

6. Roteiro Executivo de Apresentação (2 Minutos)

Pitch Rápido para Reuniões Executivas:

"O **FluxIA** transforma o canal do Telegram em uma máquina de vendas ativa com CRM integrado e Inteligência Artificial corporativa.

Diferente de soluções convencionais baseadas em bots soltos, nosso projeto foi construído sobre três diferenciais concretos:
1. Velocidade e Simplicidade Técnica: Construído em Python FastAPI com front-end puro sem frameworks pesados, garantindo carregamento instantâneo e baixo consumo de infraestrutura.
2. Inteligência Baseada em Fatos e Blindada: O bot consulta exclusivamente os arquivos oficiais da empresa. Documentos internos e confidenciais jamais são expostos a clientes externos.
3. Governança e Transparência de Custos: O gestor acompanha em tempo real quanto cada conversa custou em centavos de dólar e conta com um auditor automatizado que garante fidelidade absoluta aos preços oficiais, com transbordo imediato para operadores humanos a qualquer momento."